

# Спецкурс: системы и средства параллельного программирования

# Отчёт № 2 Оценка влияния кэша на время выполнения последовательного алгоритма блочного матричного умножения

Работу выполнил **Чепурнов А. В.** 

## Постановка задачи и формат данных

**Задача:** Реализовать последовательный алгоритм блочного матричного умножения и оценить влияние кэша на время выполнения программы. Воспользоваться системой РАРІ для сбора информации с аппаратных счётчиков.

**Формат командной строки:** <имя файла матрицы A><имя файла матрицы B><имя файла матрицы C><режим, порядок индексов><размер блока, натуральное число> Режимы: 0-ijk, 1-ikj

Размер блока по умолчанию: 32 × 32

Формат файла-матрицы: Матрица представляются в виде бинарного файла следующего формата:

Тип	Значение	Описание
Число типа char	'f' – тип float	Тип элементов матрицы
Число типа int	N – натуральное число	Число строк матрицы
Число типа int	М – натуральное число	Число столбцов матрицы
Массив чисел типа float	$N \times M$ элементов	Массив элементов матрицы

## Описание алгоритма

**Математическая постановка:** Алгоритм блочного матричного умножения заключается в блочном представлении матриц A B C. Все блоки имеют фиксированный размер  $S \times S$ . Если  $N\%S \neq 0$ , то блоки последней строки имеют размер  $N\%S \times S$ . Если  $M\%S \neq 0$ , то блоки последнего столбца имеют размер  $S \times M\%S$ . Если выполнены оба условия, то нижний правый блок имеет размер  $N\%S \times M\%S$ . Умножение  $A \times B$  и перемножение отдельных блоков осуществляется классическим последовательным алгоритмом матричного умножения. Оценка влияния кэша на время выполнения программы осуществляется за счёт изменения размера блоков и перестановки индексов суммирования. Формула определения оптимального блока для кэша:

$$S = \sqrt{\frac{size\_of\_cache}{3 * size\_of\_float}}$$

**Аппаратное обеспечение:** Вычисления проводились на отдельном ядре вычислительного комплекса IBM Polus.

L1d cache = 64K (по формуле оптимальный размер блока равен 73)

L2 cache = 512K (по формуле оптимальный размер блока равен 209)

**Анализ времени выполнения:** Для оценки времени выполнения программы использовалась функция: clock().

**Анализ информации с аппаратных счётчиков:** Для оценки влияния кэша использовались следующие средства системы PAPI:

- PAPI L1 DCM (промахи кэша 1 уровня)
- PAPI L2 DCM (промахи кэша 2 уровня)
- РАРІ\_ТОТ\_СҮС (число процессорных тактов)
- PAPI FP OPS (число операций с плавающей точкой)

Возможности считывать информацию о буфере ассоциативной трансляции (TLB) на данном аппаратном обеспечении не было.


Верификация: Для проверки корректности работы программы использовались тестовые данные.

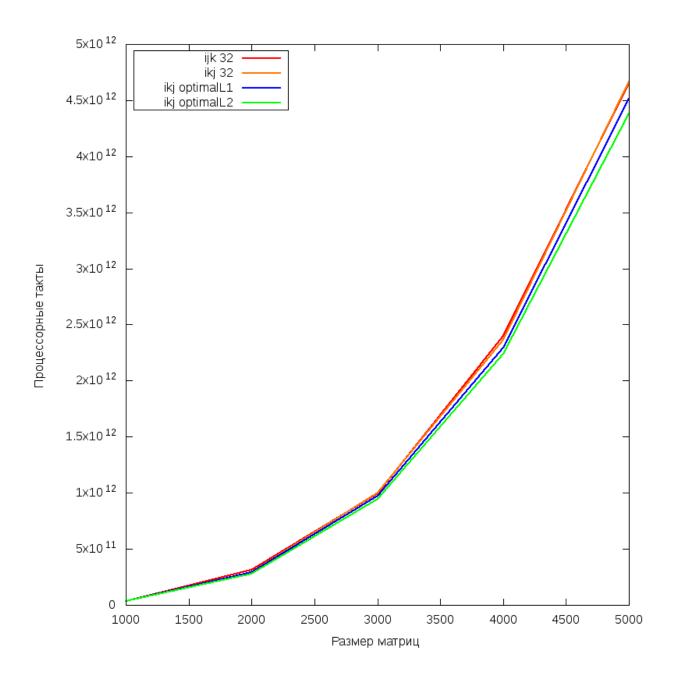
#### Основные функции:

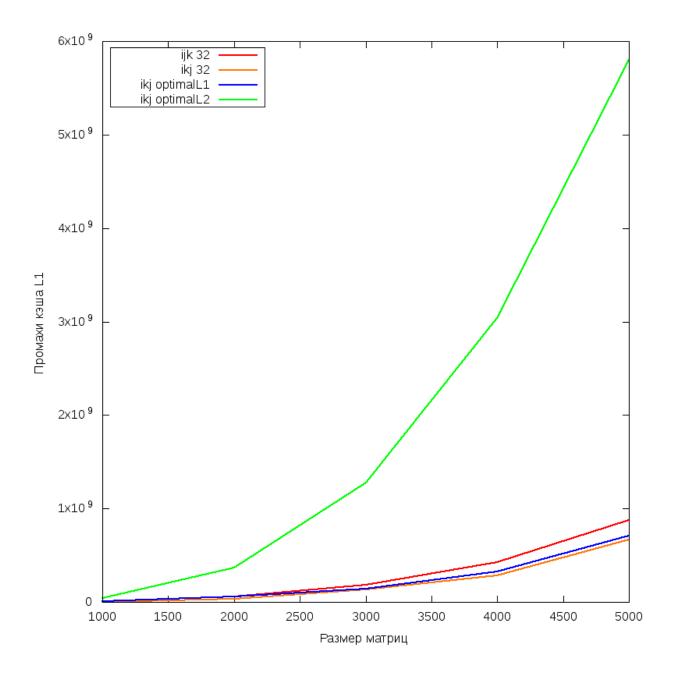
- Разбор командной строки. В рамках функции осуществляется анализ и разбор командной строки.
- Чтение файлов матриц. В рамках функции осуществляется анализ совместимости входных матриц и их чтение.
- Перемножение матриц. В рамках функции осуществляется перемножение матриц в соответствие с размерами блоков и порядком индексов суммирования.
- Сбор информации о работе. В рамках функции осуществляется подсчёт времени работы и считывание информации с аппаратных счётчиков с использованием системы PAPI.

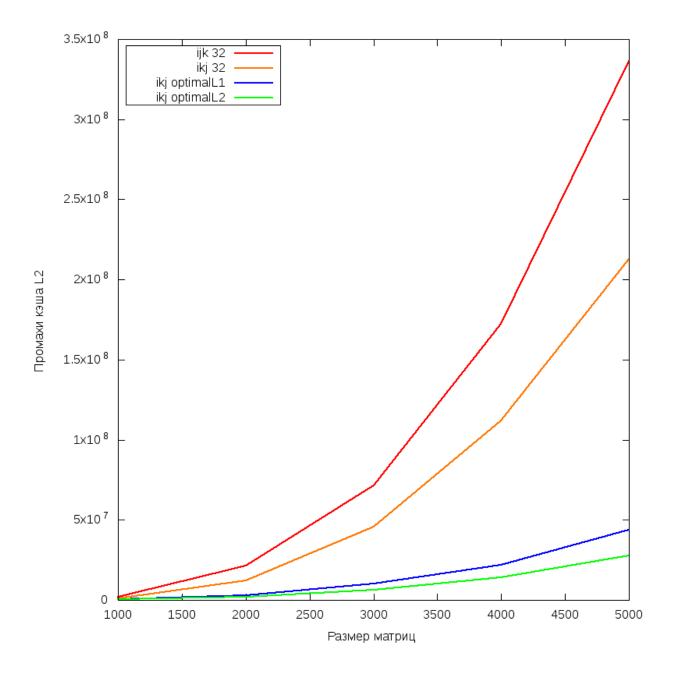
#### Результаты выполнения

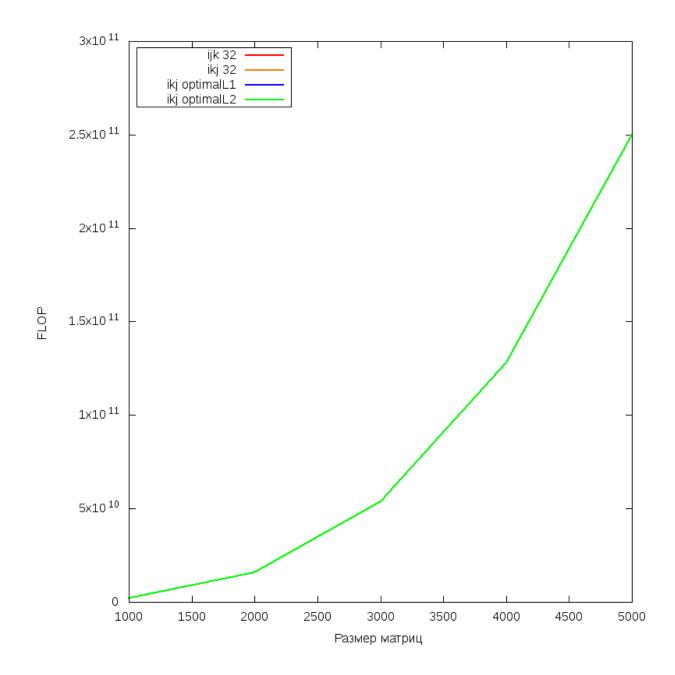
Проводилось перемножение квадратных матриц размерами  $1000 \times 1000$ ,  $2000 \times 2000$ ,  $3000 \times 3000$ ,  $4000 \times 4000$  и  $5000 \times 5000$ . Зависимость времени выполнения и числа процессорных тактов от размеров матриц представлена на графиках (время в секундах).











#### Основные выводы

Исследования показывают, что наименьшее время выполнения при оптимальном размере блока для кэша 2-го уровня (209) и порядке индексов ікј. При таком порядке весь блок умещается в кэше 2-го уровня и число его промахов снижается. Хотя число промахов кэша 1-го уровня при таких параметрах существенно больше, чем при других, общее время работы алгоритма заметно снижается (примерно на 1 минуту для матриц 5000 × 5000).

Следующий по скорости результат при оптимальном размере блока для кэша 1-го уровня (73) и порядке индексов ikj.

Наихудшее время при размере блока 32 × 32. Причем для порядка ікј все параметры лучше, чем для іјк, так как при таком порядке доступ к элементам обеих входных матриц осуществляется последовательно.

Число FLOP для каждого размера матриц при всех запусках алгоритма примерно одинаково.